Taller 5: Probabilidad y Valor P en R

Estadística II

M. Constanza Ayala

maria.ayala@uv.cl

Agenda una reunión aquí

Escuela de Sociología - Universidad de Valparaíso

07 de abril, 2026

Pasemos lista mientras descargan los materiales y dejamos todo listo ✨

📂 **Paso 1:** Abrimos nuestro proyecto con doble clic en el archivo `.Rproj`

- Si no tienen proyecto, creamos uno: `File > New Project > New Directory > New Project` — creamos carpetas: `data`, `scripts`, `figures`, `output`

💾 **Paso 2:** Movemos el archivo **"Script Taller 5 EstadisticaII.R"** a la carpeta `scripts`

📎 **Paso 3:** Hoy trabajaremos con **datos simulados**, no con bases externas

> **Todos los materiales los pueden descargar en este link:** Materiales clases

Objetivos de la clase

- Calcular **probabilidades empíricas** en R a partir de datos simulados
- Calcular **probabilidades condicionales** con tablas de contingencia
- Calcular **probabilidades bajo la distribución normal** con `pnorm()`
- Calcular el **puntaje Z** en R y usarlo para obtener probabilidades
- Calcular e interpretar el **valor P** de una prueba sobre proporciones con `prop.test()`

¿Qué vimos la última clase?

✅ Aprendimos a usar mutate() para crear nuevas variables
✅ Calculamos sumas y promedios con y sin NA
✅ Recodificamos valores perdidos con case_when()
✅ Recodificamos categorías con case_when()

💡 ¡Hoy nos movemos hacia el análisis estadístico: probabilidades y valor P!

Actividades prácticas

A lo largo de la clase realizaremos **tres actividades prácticas** para ejercitar cada función vista.

No tienen nota, pero recomiendo resolverlas en un script aparte para que quede como material de estudio.

- Crea un script nuevo (no uses el script de actividades de la clase) e incluye un título, tu nombre, correo y fecha. Por ejemplo:

```
# Actividades Taller 5 Estadística II ----------------------------------------
# M. Constanza Ayala (maria.ayala@uv.cl)
# 09-06-2026
```

Probabilidad empírica en R

La probabilidad empírica se obtiene contando frecuencias observadas:

$$P'(A) = \frac{\text{frecuencia observada}}{\text{total de intentos}}$$

Podemos simularla en R. Por ejemplo, lanzar una moneda 100 veces:

```r
set.seed(2026)                                          # Fija la semilla para reproducibilidad
lanzamientos <- sample(c("cara", "sello"),              # Vector con los posibles resultados
                       size = 100,                      # Número de lanzamientos
                       replace = TRUE)                  # Con reemplazo (cada lanzamiento es indeper

# Frecuencia observada
table(lanzamientos)
```

```
lanzamientos
 cara sello
   53    47
```

```r
# Probabilidad empírica
prop.table(table(lanzamientos))
```

```
lanzamientos
 cara sello
 0.53  0.47
```

Probabilidad condicional en R

La probabilidad condicional P(A|B) es la probabilidad de A sabiendo que B ya ocurrió:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

¿Cuál es la probabilidad de votar por X, dado que la persona es mujer?

```r
set.seed(2026)
encuesta <- data.frame(
  sexo = sample(c("Mujer", "Hombre"), 1000, replace = TRUE),  # Sin prob → probabilidad igual (50/50)
  voto = sample(c("Candidato X", "Otro"), 1000, replace = TRUE,
                prob = c(0.55, 0.45))                          # Con prob → simula que X es más votado
)
tabla <- table(encuesta$sexo, encuesta$voto)                   # Tabla de contingencia sexo × voto

prop.table(tabla, margin = 1)  # P(voto | sexo): fila es la condición
```

```
       Candidato X      Otro
Hombre   0.5787476 0.4212524
Mujer    0.5306554 0.4693446
```

```r
prop.table(tabla, margin = 2)  # P(sexo | voto): columna es la condición
```

```
       Candidato X      Otro
Hombre   0.5485612 0.5000000
Mujer    0.4514388 0.5000000
```

¿Qué responde cada tabla?

`margin = 1` → **P(voto | sexo)**

- *Dado que la persona es mujer, ¿qué probabilidad tiene de votar por el Candidato X?*
- Cada fila suma 1. La condición es el sexo.
- Útil cuando queremos saber cómo varía el voto **según** el sexo.

`margin = 2` → **P(sexo | voto)**

- *Dado que la persona votó por el Candidato X, ¿qué probabilidad hay de que sea mujer?*
- Cada columna suma 1. La condición es el voto.
- Útil cuando queremos saber cómo se compone el electorado de cada candidato.

Actividad práctica 1

En una sección del script llamada `Probabilidad`:

1. Simula el lanzamiento de un dado 1000 veces con `sample(1:6, ...)`. Calcula la probabilidad empírica de cada valor del dado con `prop.table()`. ¿Se aproxima a 1/6 ≈ 0.167?
2. Simula una encuesta de 500 personas con dos variables usando `data.frame()` y `sample()`:

- `clase_social`: "`Alta`", "`Media`", "`Baja`" (con probabilidades 0.20, 0.50, 0.30)
- `confianza_instituciones`: "`Sí`" o "`No`" (con probabilidades 0.30, 0.70)
- Calcula la probabilidad condicional P(confianza | clase social) con `prop.table()`. ¿Qué observas?

Distribución normal en R

La distribución normal describe variables continuas con forma de campana simétrica. Sus parámetros son la **media (μ)** y la **desviación estándar (σ)**.

```r
library(tidyverse)
tibble(x = seq(-4, 4, 0.01)) %>%        # Crea secuencia de valores Z entre
  mutate(densidad = dnorm(x,             # Calcula la densidad normal para
                          mean = 0,      # Media = 0 (distribución estándar
                          sd = 1)) %>%   # Desviación estándar = 1
  ggplot(aes(x = x, y = densidad)) +    # Define los ejes del gráfico
  geom_line(color = "steelblue",        # Dibuja la curva
            linewidth = 1.2) +          # Grosor de la línea
  labs(title = "Distribución Normal Estándar (μ = 0, σ = 1)",
       x = "Valor Z", y = "Densidad") + # Títulos de ejes
  theme_minimal()                        # Estilo limpio sin fondo gris
```

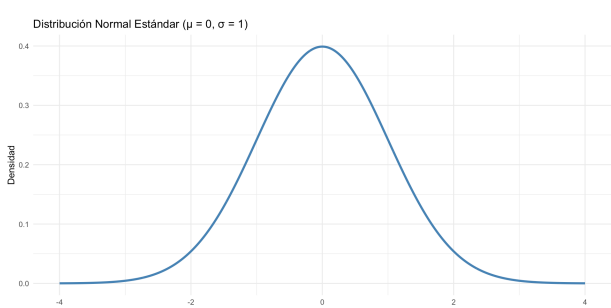

Puntaje Z en R

El puntaje Z estandariza cualquier valor de una distribución normal:

$$Z = \frac{X - \mu}{\sigma}$$

```r
# Ejemplo: ingreso mensual ~ Normal(μ = $650.000, σ = $400.000)
# ¿Cuál es el puntaje Z de una persona que gana $1.200.000?
mu <- 650000
sigma <- 400000
X <- 1200000

Z <- (X - mu) / sigma
Z
```

```
[1] 1.375
```

Un Z = 1.375 significa que este ingreso está a 1.375 desviaciones estándar **por encima** de la media, es decir, es una persona con ingresos relativamente altos respecto al promedio nacional.

Podemos calcular el puntaje Z para varios ejemplos a la vez:

```r
casos <- tibble(
  variable  = c("Ingreso mensual", "Años de escolaridad", "Puntaje autoritarismo", "Horas de trabajo
  X         = c(1200000,           8,                     65,                      38),
  mu        = c(650000,            11,                    50,                      45),
  sigma     = c(400000,            3,                     10,                      8)
)

casos <- casos %>%
  mutate(Z = (X - mu) / sigma)

casos
```

```
# A tibble: 4 × 5
  variable                      X     mu  sigma      Z
  <chr>                     <dbl>  <dbl>  <dbl>  <dbl>
1 Ingreso mensual         1200000 650000 400000  1.38
2 Años de escolaridad           8     11      3 -1
3 Puntaje autoritarismo        65     50     10  1.5
4 Horas de trabajo semanal     38     45      8 -0.875
```

> Los valores Z positivos indican que la observación está **por encima** de la media; los negativos, **por debajo**. Por ejemplo, 8 años de escolaridad y 38 horas de trabajo semanal están por debajo del promedio nacional en sus respectivas distribuciones.

Calcular probabilidades con `pnorm()`

Una vez calculado el puntaje Z, podemos obtener la probabilidad asociada con `pnorm()`, que calcula el **área bajo la curva** a la izquierda de un valor Z. Equivale a consultar la tabla Z, pero en R.

```r
# P(Z < 1.375) → probabilidad de ganar menos de $1.200.000
pnorm(1.375)
```

```
[1] 0.9154343
```

* Aproximadamente el 92% de las observaciones tienen ingresos menores a $1.200.000.

```r
# P(0 < Z < 1.375) → área entre la media y nuestro valor
pnorm(1.375) - pnorm(0)
```

```
[1] 0.4154343
```

- Cerca del 42% de las observaciones tienen ingresos entre $650.000 y $1.200.000.

```r
# P(Z > 1.375) → probabilidad de ganar más de $1.200.000
pnorm(1.375, lower.tail = FALSE)
```

```
[1] 0.08456572
```

* Solo el 8% de las observaciones tienen ingresos superiores a $1.200.000.

> También podemos pasar directamente los valores originales sin calcular Z antes:

```r
# P(ingreso entre $650.000 y $1.200.000) directamente
pnorm(1200000, mean = 650000, sd = 400000) - pnorm(650000, mean = 650000, s
```

```
[1] 0.4154343
```

Prob. con valores Z negativos

Los Z negativos corresponden a valores **por debajo** de la media — como los casos de escolaridad y horas de trabajo que vimos antes:

```r
# P(Z < -1) → probabilidad de tener menos de 8 años de escolaridad
pnorm(-1)
```

```
[1] 0.1586553
```

- Aproximadamente el 16% de las observaciones tienen menos de 8 años de escolaridad.

```r
# P(-0.875 < Z < 1.375) → probabilidad de trabajar entre 38 y 50 horas semanales
pnorm(1.375) - pnorm(-0.875)
```

```
[1] 0.7246473
```

* Cerca del 73% de las observaciones trabajan entre 38 y 50 horas semanales.

```r
# P(Z > -0.875) → probabilidad de trabajar más de 38 horas semanales
pnorm(-0.875, lower.tail = FALSE)
```

```
[1] 0.809213
```

* Aproximadamente el 81% de las observaciones trabajan más de 38 horas semanales.

Actividad práctica 2

En una sección del script llamada `Puntaje Z y pnorm`:

1. Calcula el puntaje Z para las siguientes situaciones y luego la probabilidad con `pnorm()`:
   a. Puntajes de ansiedad con $\mu = 50$ y $\sigma = 12$. ¿Cuál es la probabilidad de obtener entre 50 y 62 puntos?
   b. Salarios con $\mu = 500.000$ y $\sigma = 80.000$. ¿Cuál es la probabilidad de ganar **más de** $580.000?
   c. Estaturas con $\mu = 170$ y $\sigma = 8$. ¿Cuál es la probabilidad de medir **menos de** 162 cm?
2. Para el caso (a), verifica que obtienes el mismo resultado calculando primero el Z manualmente y luego usando `pnorm(Z)`, y usando `pnorm(62, mean = 50, sd = 12) - pnorm(50, mean = 50, sd = 12)`.

Del puntaje Z al valor P

- El **valor P** es la probabilidad de obtener un resultado igual o más extremo que el observado, asumiendo que la hipótesis nula (H_0) es verdadera.

- En términos prácticos: el valor P es un **área bajo la curva normal**, exactamente lo que calcula `pnorm()`.

Nivel de significancia y valores críticos

Recordemos la relación entre α y los valores Z críticos, que podemos obtener con `qnorm()`:

```r
qnorm(0.975)   # Z crítico para α = 0.05 (dos colas)
```

```
[1] 1.959964
```

```r
qnorm(0.995)   # Z crítico para α = 0.01 (dos colas)
```

```
[1] 2.575829
```

```r
qnorm(0.950)   # Z crítico para α = 0.10 (dos colas)
```

```
[1] 1.644854
```

Nivel de confianza	α	Z crítico (dos colas)
90%	0.10	±1.645
95%	0.05	±1.960
99%	0.01	±2.576

Hipótesis nula y alternativa

Antes de calcular el valor P, siempre formulamos las hipótesis:

- **H_0** (nula): afirma que NO hay diferencia o relación — siempre incluye “igual a”
- **H_a** (alternativa): lo que queremos demostrar

La dirección de H_a determina el tipo de prueba:

H_a	Tipo de prueba	`alternative` en R
p ≠ valor	Dos colas	`"two.sided"`
p > valor	Una cola derecha	`"greater"`
p < valor	Una cola izquierda	`"less"`

> H_0 siempre se formula como la negación de lo que queremos demostrar. Se asume verdadera hasta que la evidencia diga lo contrario.

Ejemplo 1: Género en cargos directivos (valor P > 0.05)

En Chile, se espera que el 50% de los cargos directivos sean ocupados por mujeres si hubiera paridad. En una muestra de 120 empresas, se observa que el 44% de los cargos directivos son ocupados por mujeres. ¿Es esta proporción significativamente diferente del 50%?

- **H_0**: $p = 0.50$ — **H_a**: $p \neq 0.50$ — **$\alpha = 0.05$**

```r
prop.test(x = 53, n = 120, p = 0.50, alternative = "two.sided")
```

```
	1-sample proportions test with continuity correction

data:  53 out of 120, null probability 0.5
X-squared = 1.4083, df = 1, p-value = 0.2353
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.3520466 0.5350727
sample estimates:
        p
0.4416667
```

Interpretando el resultado

Valor P = 0.235

Decisión con α = 0.05:

- 0.235 > 0.05 → **No rechazamos H_0**
- La diferencia entre 0.44 y 0.50 **no es estadísticamente significativa**
- Conclusión: no hay evidencia suficiente de que la proporción de mujeres en cargos directivos sea diferente del 50%

> Esto no significa que haya paridad real, solo que con esta muestra de 120 empresas no tenemos suficiente evidencia estadística para afirmar lo contrario. Con una muestra mayor, el resultado podría cambiar.

Visualizando el valor P

```r
# Calculamos el Z observado para nuestra proporción (44% vs 50% esperado)
z_obs <- (0.44 - 0.50) / sqrt(0.50 * 0.50 / 120)

tibble(x = seq(-4, 4, 0.01)) %>%
  mutate(y = dnorm(x)) %>%                          # Densidad normal estándar
  ggplot(aes(x = x, y = y)) +
  geom_line(color = "steelblue", linewidth = 1) +       # Curva normal
  geom_area(data = . %>% filter(x <= -abs(z_obs)),      # Área cola izquierda
            fill = "#E74C3C", alpha = 0.4) +
  geom_area(data = . %>% filter(x >= abs(z_obs)),       # Área cola derecha
            fill = "#E74C3C", alpha = 0.4) +
  geom_vline(xintercept = c(-abs(z_obs), abs(z_obs)),   # Líneas en Z observado
             linetype = "dashed", color = "#E74C3C") +
  labs(title = "Distribución normal bajo H₀ — Género en cargos directivos",
       subtitle = paste0("Área sombreada = valor P = ",
                         round(2 * pnorm(-abs(z_obs)), 3),  # Valor P de dos colas
                         " → No rechazamos H₀"),
       x = "Valor Z", y = "Densidad") +
  theme_minimal()
```

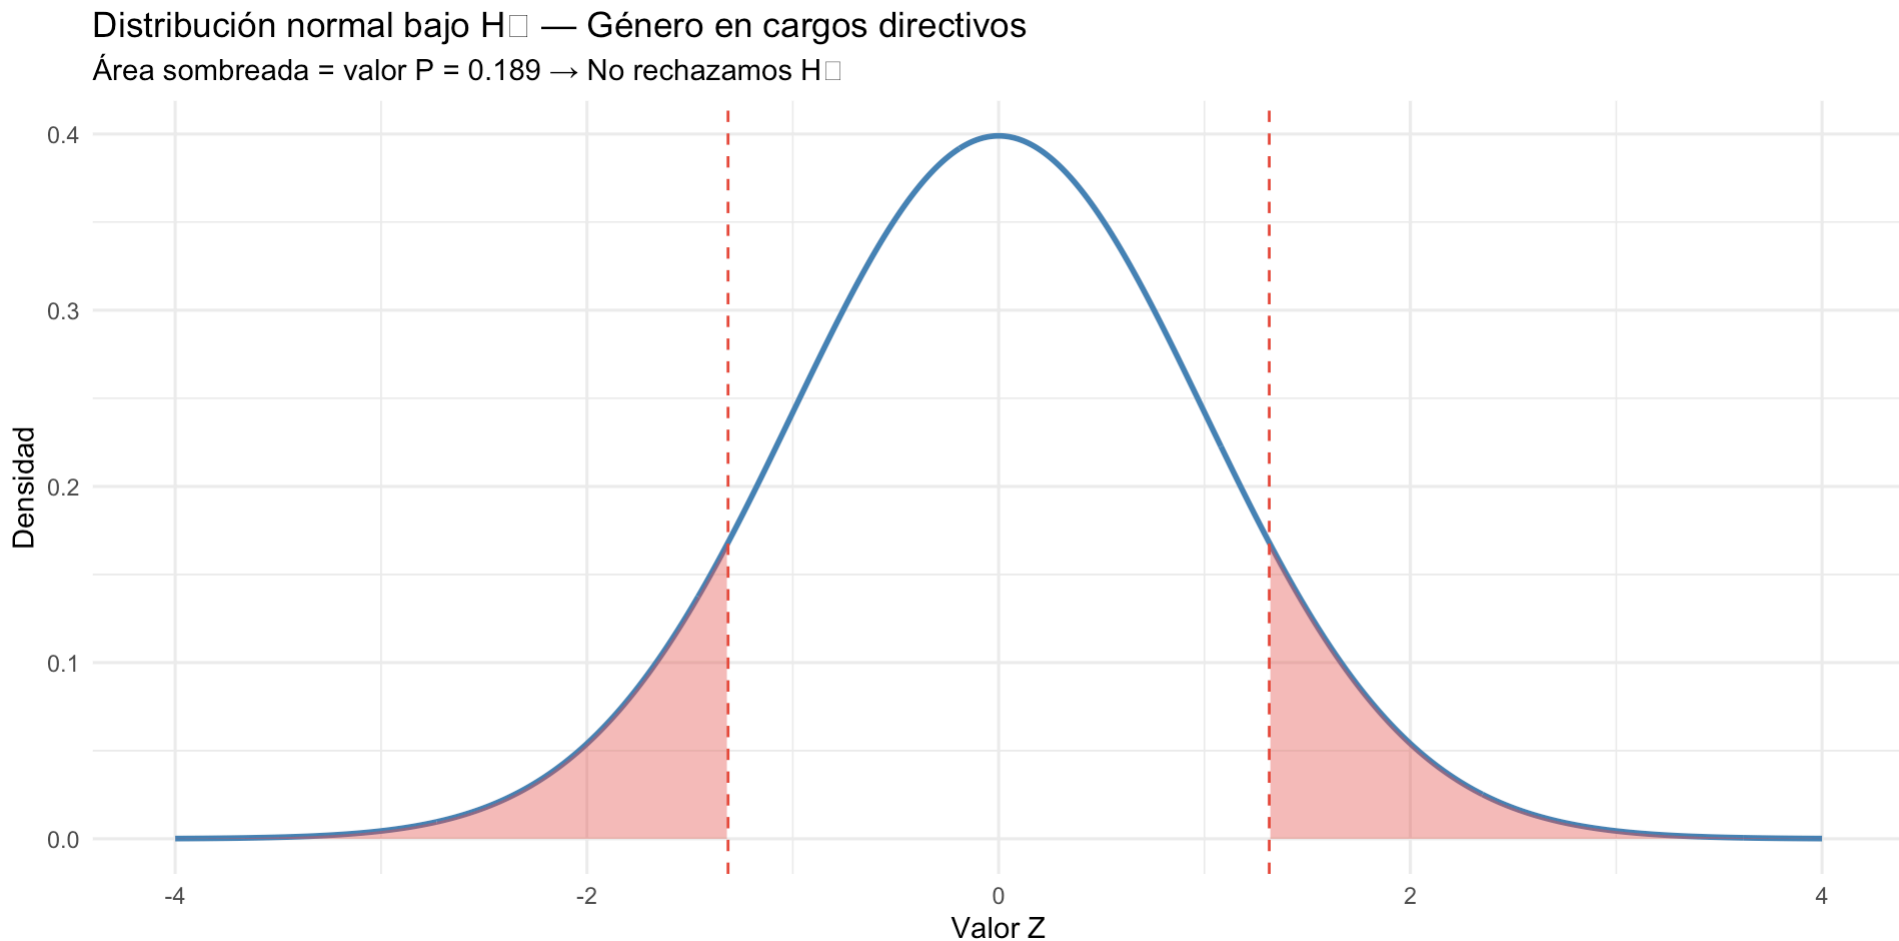
Distribución normal bajo H□ — Género en cargos directivos
Área sombreada = valor P = 0.189 → No rechazamos H□
Densidad
0.4
0.3
0.2
0.1
0.0
-4
-2
0
2
4
Valor Z

Ejemplo 2: Pueblos originarios en el mercado laboral (valor P ≈ 0)

Según el Censo 2017, el 12.8% de la población chilena pertenece a un pueblo originario. En una muestra de 300 trabajadores de una empresa minera, solo el 6% declara pertenecer a un pueblo originario. ¿Es esta proporción significativamente diferente de la esperada?

- **H_0**: $p = 0.128$ — **H_a**: $p \neq 0.128$ — **$\alpha = 0.05$**

```r
prop.test(x = 18, n = 300, p = 0.128, alternative = "two.sided")
```

```
	1-sample proportions test with continuity correction

data:  18 out of 300, null probability 0.128
X-squared = 11.827, df = 1, p-value = 0.0005839
alternative hypothesis: true p is not equal to 0.128
95 percent confidence interval:
 0.03697912 0.09481798
sample estimates:
   p
0.06
```

Interpretando el resultado

Valor P = 6^{-4}

Decisión con α = 0.05:

- 6^{-4} < 0.05 → **Rechazamos H_0**
- La diferencia **sí es estadísticamente significativa**
- Conclusión: la proporción de trabajadores pertenecientes a pueblos originarios en esta empresa es significativamente **menor** que en la población general

> Este resultado es sustantivamente relevante: sugiere una posible subrepresentación de pueblos originarios en el empleo formal de la empresa, lo que podría indicar barreras de acceso al mercado laboral.

Ejemplo 3: El nivel de significancia (α)

En 200 empresas, el 57% de los cargos directivos son ocupados por hombres. ¿Es esta proporción significativamente diferente del 50%?

```r
prop.test(x = 114, n = 200, p = 0.50, alternative = "two.sided")
```

```
	1-sample proportions test with continuity correction

data:  114 out of 200, null probability 0.5
X-squared = 3.645, df = 1, p-value = 0.05624
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.4982053 0.6390612
sample estimates:
   p
0.57
```

El valor P obtenido es 0.056. La decisión depende del α elegido:

α	Decisión	Conclusión
0.05	0.056 > 0.05 → **No rechazamos H_0**	No hay evidencia de diferencia
0.10	0.056 < 0.10 → **Rechazamos H_0**	Sí hay evidencia de diferencia

Lo que el valor P sí y no significa

El valor P **sí significa:**

✅ La probabilidad de observar estos datos (o más extremos) si H_0 fuera verdadera
✅ Una medida de compatibilidad entre los datos y H_0
✅ Cuanto más pequeño, mayor la evidencia en contra de H_0

El valor P **no significa:**

❌ La probabilidad de que H_0 sea verdadera
❌ Una medida del tamaño o importancia del efecto
❌ Que un resultado significativo sea necesariamente relevante

Actividad práctica 3

En una sección del script llamada `Valor P`:

1. Según la Encuesta Nacional de Uso del Tiempo (ENUT), el 65% de las mujeres realiza trabajo doméstico no remunerado de forma cotidiana. En una muestra de 150 mujeres de una región específica, 85 declaran realizar estas tareas diariamente. ¿Es esta proporción significativamente diferente del 65% nacional?

   a. Formula H_0 y H_a.

   b. Aplica `prop.test()` con $\alpha = 0.05$.

   c. ¿Rechazas o no rechazas H_0? Escribe la conclusión.

   d. ¿Cambia la decisión con $\alpha = 0.10$?

2. Calcula manualmente el valor P para $Z = 1.96$ usando `pnorm()` (prueba de dos colas). ¿Qué observas?

❓ Preguntas y aclaraciones

💬 **¿Dudas sobre lo visto hoy?**

- Tómense un momento para reflexionar y compartir preguntas sobre el contenido.
- Espacio para responder inquietudes y aclarar conceptos clave.

Resumen clase de hoy

✅ Calculamos probabilidades empíricas y condicionales en R

✅ Calculamos el puntaje Z y lo usamos para obtener probabilidades con `pnorm()`

✅ Realizamos pruebas de hipótesis sobre proporciones con `prop.test()`

✅ Interpretamos el valor P en relación con α

📅 Próxima sesión

- Intervalos de confianza en R

📚 Sugerencias lecturas para reforzar R

- Wickham & Grolemund. R for Data Science (acceso en línea biblioteca, en español: https://es.r4ds.hadley.nz/)
- AnalizaR Datos Políticos
- YaRrr! The Pirate's Guide to R