

Taller 9: Muestreo en R

Estadística II

M. Constanza Ayala

maria.ayala@uv.cl

[Agenda una reunión aquí](#)

Escuela de Sociología - Universidad de Valparaíso

26 de mayo, 2026

Pasemos lista mientras descargan los materiales y dejamos todo listo ✨

 **Paso 1:** Abrimos nuestro proyecto con doble clic en el archivo `.Rproj`

- Si no tienen proyecto, creamos uno: `File > New Project > New Directory > New Project` — creamos carpetas: `data`, `scripts`, `figures`, `output`

 **Paso 2:** Movemos el archivo “Script Taller 9 Estadistical.R” a la carpeta `scripts`

 **Paso 3:** Verificamos que la base `base_92_20112024.Rds` esté en la carpeta `data`

Todos los materiales los pueden descargar en este link: [Materiales clases](#)

Objetivos de la clase

- Recordar los principales **tipos de muestreo probabilístico**
- Simular el proceso de **muestreo aleatorio simple** con `sample_n()` y `map_db1()`
- Aplicar **muestreo estratificado** con el paquete `sampling`
- Aplicar **muestreo por conglomerados** con el paquete `sampling`

¿Qué vimos la última clase?

- ✓ Calculamos IC para proporciones de forma manual con `summarise()`
- ✓ Calculamos IC para proporciones con `BinomCI()` (método de Wald)
- ✓ Comparamos IC obtenidos con distintos niveles de confianza

💡 ¡Hoy damos el paso hacia el **diseño muestral** en R!

Actividades prácticas

A lo largo de la clase realizaremos **tres actividades prácticas**, una por tipo de muestreo.

No tienen nota, pero recomiendo resolverlas en un script aparte para que quede como material de estudio.

- Crea un script nuevo e incluye un título, tu nombre, correo y fecha:

```
1 # Actividades Taller 9 Estadística II -----  
2 # M. Constanza Ayala (maria.ayala@uv.cl)  
3 # 26-05-2026
```

Universo, marco muestral y muestra

- **Universo:** conjunto completo de elementos que la investigación busca estudiar — es el referente teórico de la inferencia.
- **Marco muestral:** lista operacional desde la cual se extrae la muestra (idealmente cubre todo el universo).
- **Muestra:** subconjunto seleccionado del marco. Si la selección fue aleatoria → se puede generalizar al universo con error conocido.

CEP 92

Datos de la muestra

Población objetivo

Población de 18 años y más residente en todo el país (a excepción de Isla de Pascua, Juan Fernández y la Antártica).

Diseño muestral

El diseño de la muestra es probabilístico estratificado por región y zona urbana y rural, la selección es aleatoria en cada una de sus tres etapas (manzana-hogar-entrevistado).

1.482 personas entrevistadas en sus hogares en 127 comunas del país.

El error muestral se estima en +2,8% considerando varianza máxima, un nivel de confianza de 95% y un efecto diseño de 1,2.

Modo de aplicación

Entrevistas realizadas por un encuestador/a cara a cara, basadas en un cuestionario estructurado.


Tasa de respuesta

61,3% que corresponde a las 1.482 encuestas completas sobre la muestra total de 2.416.

Fecha de trabajo de campo

La recolección de datos se efectuó entre el 02 de agosto y el 12 de septiembre 2024.

Diseño muestral



1. Población de Estudio
(Unidad de análisis)
2. Marco Muestral
3. Muestra
seleccionada

Tipos de muestreo probabilístico: definiciones

- **Aleatorio simple (MAS)** Todos los casos tienen igual probabilidad de ser seleccionados. No se usa información auxiliar de la población.
- **Sistemático** Se selecciona cada k -ésimo elemento de la lista ($k = N/n$). Parte de un primer sujeto elegido al azar.
- **Estratificado** La población se divide en subpoblaciones no superpuestas (estratos) y se sortea de forma independiente dentro de cada uno.
- **Por conglomerados** La población se divide en grupos naturales (comunidades, escuelas, regiones) y se seleccionan aleatoriamente algunos grupos completos.
- **Multietápico** Combina dos o más de los métodos anteriores sobre distintas unidades — por ejemplo, estratos de regiones → conglomerados de manzanas → MAS de individuos. Es el diseño de la CEP.

En este taller implementamos en R: MAS, estratificado y conglomerados.

Carguemos los paquetes y la base de datos

```
1 library(tidyverse)
2 library(haven)
3 library(sampling)
4
5 data <- readRDS("data/base_92_20112024.Rds")
6
7 data %>% glimpse()
```

Rows: 1,482

Columns: 157

```
$ id_bu          <chr> "1-92", "2-92", "3-92", "4-92", "5-92", "6-92", "7-
9..."
$ id_bu_encuesta <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15,
1..."
$ encuesta       <dbl> 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92,
...
$ encuesta_a     <dbl> 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024,
2024...
$ encuesta_m     <dbl> 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8,
8...
$ pond          <dbl> 0.2096586, 1.2242271, 0.4620447, 1.6158843,
```

Preparación: recodificar valores perdidos

Antes de trabajar con cualquier variable, recodificamos los valores no válidos como NA:

```
1 data <- data %>%
2   mutate(
3     democracia_19 = case_when(
4       democracia_19 %in% c(-8, -9) ~ NA_real_,
5       TRUE ~ democracia_19
6     ),
7     bienestar_2 = case_when(
8       bienestar_2 %in% c(-8, -9) ~ NA_real_,
9       TRUE ~ bienestar_2
10    )
11  )
```

democracia_19: preferencia entre libertades públicas (1) y orden público (10) ·

bienestar_2: satisfacción con la vida (1–10).

Valores de referencia

Antes de simular muestras, calculamos los estadísticos en la base completa. La CEP 92 es en sí misma una muestra, no la población chilena, pero para este ejercicio **la trataremos como nuestra población de referencia**: extraeremos submuestras de ella y las compararemos.

```
1 data %>%  
2   summarise(  
3     media_democracia = mean(democracia_19, na.rm = TRUE),  
4     media_satisf     = mean(bienestar_2,   na.rm = TRUE),  
5     n                = n()  
6   )
```

```
# A tibble: 1 × 3  
  media_democracia media_satisf     n  
    <dbl>          <dbl> <int>  
1      8.21         7.56  1482
```

Esto nos permitirá ver cómo varía una estimación muestral respecto al valor que la muestra completa entrega, simulando la lógica de la inferencia estadística.

Muestreo Aleatorio Simple (MAS)

Seleccionamos casos de forma completamente aleatoria, donde **cada unidad del marco tiene la misma probabilidad** de ser incluida en la muestra.

En R usamos `sample_n()` del paquete `dplyr`:

```
1 sample_n(data,          # base de datos (el "marco muestral")
2   size = 10, # tamaño de la muestra
3   replace = FALSE) # sin reemplazo (por defecto); FALSE → cada persona se selecciona máximo una
```

A tibble: 10 × 157

	id_bu	id_bu_encuesta	encuesta	encuesta_a	encuesta_m	pond	secu	estrato
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	177-92	177	92	2024	8	0.666	92188	20
2	1013-92	1013	92	2024	8	0.721	92017	3
3	981-92	981	92	2024	8	0.728	92247	20
4	341-92	341	92	2024	8	0.411	92289	13
5	1003-92	1003	92	2024	8	1.23	92027	4
6	338-92	338	92	2024	8	1.29	92232	20
7	260-92	260	92	2024	8	0.966	92079	10
8	115-92	115	92	2024	8	0.757	92113	14
9	402-92	402	92	2024	8	0.714	92170	20
10	426-92	426	92	2024	8	0.652	92002	1

i 149 more variables: region_3 <dbl+lbl>, zona_u_r <dbl+lbl>, gse <dbl+lbl>,
percepcion_1_a <dbl+lbl>, percepcion_1_b <dbl+lbl>,
percepcion_1_c <dbl+lbl>, percepcion_2 <dbl+lbl>, percepcion_3 <dbl+lbl>,
bienestar_2 <dbl+lbl>, bienestar_7_a <dbl+lbl>, bienestar_7_d <dbl+lbl>,
bienestar_7_f <dbl+lbl>, bienestar_7_g <dbl+lbl>, percepcion_5 <dbl+lbl>,

MAS: una muestra

```
1 set.seed(2026) # fija la semilla para reproducibilidad
2
3 muestra_mas <- data %>%
4   sample_n(100)
5
6 # Estimamos el promedio en esta muestra
7 mean(muestra_mas$democracia_19, na.rm = TRUE)
```

```
[1] 7.47
```

El resultado difiere del valor que obtuvimos con la base completa (8.21). Esto es esperable: cada muestra captura una fracción distinta de los datos. Si volviéramos a extraer 100 casos distintos, obtendríamos otro valor. A esto se le llama variabilidad muestral

MAS: con y sin reemplazo

```
1 # Sin reemplazo: un caso solo puede aparecer una vez (lo más común)
2 muestra_sin <- data %>% sample_n(100, replace = FALSE)
3
4 # Con reemplazo: un caso puede ser seleccionado más de una vez
5 muestra_con <- data %>% sample_n(100, replace = TRUE)
6
7 # Verificamos duplicados
8 table(duplicated(muestra_sin$id_bu))
```

```
FALSE
100
```

```
1 table(duplicated(muestra_con$id_bu))
```

```
FALSE  TRUE
  98     2
```

El muestreo **con reemplazo** simula poblaciones infinitas, lo que permite repetir el proceso de muestreo muchas veces sobre la misma base sin agotarla. En encuestas presenciales, como la CEP, se usa siempre **sin reemplazo**.

¿Y si repetimos el muestreo muchas veces?

Cada muestra produce una estimación diferente. Si repetimos el proceso 1000 veces podemos visualizar la **distribución muestral** de la media, es decir, cómo se comporta el estimador en el largo plazo.

Para esto usamos `map_dbl()` del paquete `purrr` (parte de `tidyverse`):

```
1 simulaciones <- map_dbl(1:1000, ~{  
2   muestra <- sample_n(data, 100)           # tomamos una muestra  
3   mean(muestra$democracia_19, na.rm = TRUE) # calculamos su media  
4 })  
5  
6 mean(simulaciones)
```


```
[1] 8.219324
```

En lugar de repetir el mismo código 1000 veces, `map_dbl()` automatiza el proceso y devuelve un vector de 1000 medias muestrales.

Distribución muestral de la media

```
1 hist(simulaciones,  
2     probability = TRUE,           # escala de densidad (no frecuencia)  
3     main = "Distribución de 1000 medias muestrales (n = 100 c/u)", # título  
4     xlab = "Media democracia_19", # etiqueta eje x  
5     col = "darkgrey", border = "white") # color barras y bordes  
6 curve(dnorm(x, mean = mean(simulaciones), sd = sd(simulaciones)), # curva normal teórica  
7     col = "red", lwd = 2, add = TRUE) # color rojo, grosor 2, sobre el histograma  
8 abline(v = mean(simulaciones), col = "blue", lty = 2, lwd = 2) # línea vertical en la media
```

Distribución de 1000 medias muestrales (n = 100 c/u)



Interpretación

- Las medias muestrales se distribuyen **aproximadamente de forma normal** alrededor del valor de la base completa.
- Esta propiedad se sostiene **aunque la variable original no sea normal**, es lo que garantiza el Teorema Central del Límite (TCL).
- La dispersión del histograma representa el **error estándar**: cuanto mayor sea el tamaño muestral n , más estrecha es la distribución y más precisa la estimación.
- Este es el fundamento matemático que permite hacer **inferencia estadística** a partir de una sola muestra.

Actividad práctica 1 - MAS

En una sección del script llamada `Muestreo Aleatorio Simple`:

1. Carga los paquetes `tidyverse`, `haven` y `sampling`. Carga la base `base_92_20112024.Rds`. Recodifica los valores `-8` y `-9` como `NA` en `bienestar_2` con `mutate()` y `case_when()`.
2. Fija la semilla con `set.seed(2026)` y extrae una muestra aleatoria simple de **200 casos** con `sample_n()`. Guárdala como `muestra_mas`.
3. Calcula la media de `bienestar_2` (satisfacción con la vida) en la muestra. Compárala con la media en la base completa. Escribe como comentario (`#`) qué diferencia observas.
4. Repite el muestreo 1000 veces usando `map_db1()` y construye el histograma de medias muestrales. Escribe como comentario (`#`) qué forma tiene la distribución y por qué.

Muestreo Estratificado

La población se divide en **estratos homogéneos** y se extrae una muestra aleatoria dentro de cada uno, asegurando su representación proporcional en la muestra final.

¿Por qué estratificar?

- Con MAS puro, un grupo pequeño podría quedar con muy pocos casos por azar. El muestreo estratificado **garantiza** que cada subgrupo esté representado en la proporción que corresponde a su tamaño real en la población.
- En R usamos `strata()` del paquete `sampling`.

Estratificado por sexo

```
1 # Revisamos la distribución del estrato
2 table(data$sexo)
```

```
1 2
577 905
```

```
1 prop.table(table(data$sexo))
```

```
1 2
0.3893387 0.6106613
```

```
1 # 1 = Hombre (39%), 2 = Mujer (61%)
```

```
1 # La base debe estar ordenada por la variable de estrato
2 data <- data %>% arrange(sexo)
3
4 # Definimos el tamaño proporcional: n = 150 → ~39% Hombre, ~61% Mujer
5 estratos <- strata(data,
6                     stratanames = c("sexo"), # variable de estrato
7                     size = c(58, 92),      # ni por estrato (proporcional a 150)
8                     method = "srswor")      # muestreo sin reemplazo dentro de cada estrato
9
10 table(estratos$sexo)
```

```
1 2
58 92
```

Extraer la muestra estratificada

```
1 # Extraemos los datos de la muestra
2 muestra_estrat <- getdata(data, estratos)
3
4 # Verificamos la distribución resultante
5 table(muestra_estrat$sexo)
```

```
1 2
58 92
```

```
1 prop.table(table(muestra_estrat$sexo))
```

```
1 2
0.3866667 0.6133333
```

```
1 # Estimamos la media de democracia_19 por estrato
2 muestra_estrat %>%
3 group_by(sexo) %>%
4 summarise(
5   media_democracia = mean(democracia_19, na.rm = TRUE),
6   n                 = n()
7 )
```

```
# A tibble: 2 × 3
  sexo      media_democracia    n
<dbl> <dbl> <int>
1 1 [Hombre]          7.70     58
2 2 [Mujer]           8.44     92
```

Estratificado por dos variables

También podemos estratificar por dos variables simultáneamente — por ejemplo, sexo y GSE:

```
1 # Recodificamos GSE a 4 categorías (D y E juntos)
2 data <- data %>%
3   mutate(gse_4cat = case_when(
4     gse %in% c(4, 5) ~ 4,
5     TRUE           ~ gse
6   ))
7
8 # Ordenamos por ambas variables de estrato
9 data <- data %>% arrange(sexo, gse_4cat)
10
11 # 2 × 4 = 8 estratos, 10 casos por estrato
12 estratos_2 <- strata(data,
13                       stratanames = c("sexo", "gse_4cat"),
14                       size = rep(10, 8),
15                       method = "srswor")
16
17 muestra_estrat_2 <- getdata(data, estratos_2)
18 table(muestra_estrat_2$sexo, muestra_estrat_2$gse_4cat)
```

```
   1  2  3  4
1 10 10 10 10
2 10 10 10 10
```

Actividad práctica 2 - Estratificado

En una sección del script llamada `Muestreo Estratificado`:

1. Revisa la distribución de `zona_u_r` con `table()` y `prop.table()`.
2. Calcula manualmente el tamaño proporcional para cada estrato con $n = 150$ e inclúyelo como comentario (`#`) en el script.
3. Ordena la base por `zona_u_r` con `arrange()` y extrae una muestra estratificada con `strata()` usando los tamaños que calculaste.
4. Extrae la muestra con `getdata()` y verifica la distribución resultante con `table()` y `prop.table()`.
5. Calcula la media de `bienestar_2` por zona con `group_by()` y `summarise()`. Escribe como comentario (`#`) qué diferencias observas.

Muestreo por Conglomerados

La población se divide en **grupos naturales o conglomerados** (comunas, escuelas, regiones) y se seleccionan aleatoriamente algunos de estos grupos. Todos los elementos dentro de los grupos seleccionados conforman la muestra, o bien se realiza una segunda etapa de selección dentro de ellos.

¿Cuándo usarlo?

- Cuando la población está geográficamente dispersa y contar con un marco completo de individuos es inviable o muy costoso. Es el diseño más común en encuestas nacionales cara a cara (como la CEP).

Conglomerados: selección de grupos

```
1 # Revisamos las macro-zonas disponibles como conglomerados
2 table(data$region_3)
```

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
29	42	26	64	162	77	87	141	70	67	10	11	597	38	15	46

```
1 # Seleccionamos 3 macro-zonas al azar
2 muestra_conglom <- cluster(data,
3                             clustername = "region_3", # variable de conglomerados
4                             size = 3,                # número de grupos a seleccionar
5                             method = "srswor")
6
7 # Extraemos los datos de las zonas seleccionadas
8 muestra_conglom_final <- getdata(data, muestra_conglom)
9
10 # ¿Qué macro-zonas fueron seleccionadas?
11 unique(muestra_conglom_final$region_3)
```

```
<labelled<double>[3]>: Región (nombre)
```

```
[1] 5 6 8
```

Labels:

value

label

- 1 Tarapacá
- 2 Antofagasta
- 3 Atacama
- 4 Coquimbo
- 5 Valparaíso
- 6 O'Higgins'
- 7 Maule
- 8 Biobío
- 9 La Araucanía

Conglomerados: segunda etapa

En el muestreo por conglomerados en dos etapas, dentro de cada grupo seleccionado se realiza una segunda selección aleatoria:

```
1 # Segunda etapa: 30 casos por macro-zona seleccionada
2 muestra_2etapas <- muestra_conglom_final %>%
3   group_by(region_3) %>%
4   slice_sample(n = 30) %>%
5   ungroup()
6
7 table(muestra_2etapas$region_3)
```

```
5 6 8
30 30 30
```

```
1 # También podemos seleccionar una proporción en vez de un número fijo
2 muestra_2etapas_prop <- muestra_conglom_final %>%
3   group_by(region_3) %>%
4   slice_sample(prop = 0.50) %>% # 50% de cada grupo
5   ungroup()
6
7 table(muestra_2etapas_prop$region_3)
```

```
5 6 8
81 38 70
```

Actividad práctica 3 - Conglomerados

En una sección del script llamada `Muestreo por Conglomerados`:

1. Selecciona **4 macro-zonas** al azar con `cluster()` usando `region_3` como conglomerado.
2. Extrae los datos con `getdata()` y verifica qué macro-zonas fueron seleccionadas con `unique()`.
3. Aplica una segunda etapa seleccionando el **40%** de los casos dentro de cada macro-zona con `slice_sample(prop = 0.40)`. Verifica la distribución con `table()`.
4. Calcula la media de `bienestar_2` (satisfacción con la vida) en la muestra de dos etapas con `summarise()`. Escribe como comentario (`#`) cómo se compara con el valor poblacional calculado al inicio de la clase.

Comparación entre tipos de muestreo

Comparamos las estimaciones de cada diseño con el valor de la base completa:

```
1 # Valor de referencia (base CEP completa)
2 media_ref <- mean(data$democracia_19, na.rm = TRUE)
3
4 # Media en muestra MAS (n = 100)
5 media_mas <- mean(muestra_mas$democracia_19, na.rm = TRUE)
6
7 # Media en muestra estratificada
8 media_est <- mean(muestra_estrat$democracia_19, na.rm = TRUE)
9
10 # Media en muestra conglomerados (dos etapas)
11 media_cong <- mean(muestra_2etapas$democracia_19, na.rm = TRUE)
12
13 tibble(
14   tipo = c("Base completa (ref.)", "MAS", "Estratificado", "Conglomerados"),
15   media = round(c(media_ref, media_mas, media_est, media_cong), 3)
16 )
```

A tibble: 4 × 2

tipo	media
<chr>	<dbl>
1 Base completa (ref.)	8.21
2 MAS	7.47
3 Estratificado	8.15
4 Conglomerados	8.34

Recuerda: la base completa es también una muestra, no la población real. Las

? Preguntas y aclaraciones

 ¿Dudas sobre lo visto hoy?

- Tómense un momento para reflexionar y compartir preguntas sobre el contenido.
- Espacio para responder inquietudes y aclarar conceptos clave.

Resumen clase de hoy

- ✓ Distinguimos los conceptos de universo, marco muestral y muestra
- ✓ Identificamos los tipos de muestreo probabilístico y cuándo usar cada uno
- ✓ Aplicamos MAS con `sample_n()` y visualizamos la distribución muestral con `map_dbl()`
- ✓ Aplicamos muestreo estratificado con `strata()` y `getdata()`
- ✓ Aplicamos muestreo por conglomerados con `cluster()` en dos etapas



Próxima sesión

- Pruebas de hipótesis



Sugerencias lecturas para reforzar R

- Wickham & Grolemund. R for Data Science (acceso en línea biblioteca, en español: <https://es.r4ds.hadley.nz/>)
- [AnalizaR Datos Políticos](#)
- [YaRrr! The Pirate's Guide to R](#)