

Taller 11: Chi-cuadrado en R

Estadística II

M. Constanza Ayala

maria.ayala@uv.cl

[Agenda una reunión aquí](#)

Escuela de Sociología - Universidad de Valparaíso

09 de junio, 2026

Pasemos lista mientras descargan los materiales y dejamos todo listo ✨

 **Paso 1:** Abrimos nuestro proyecto con doble clic en el archivo `.Rproj`

- Si no tienen proyecto, creamos uno: `File > New Project > New Directory > New Project` — creamos carpetas: `data`, `scripts`, `figures`, `output`

 **Paso 2:** Movemos el archivo “`Script Taller 11 EstadisticaI.R`” a la carpeta `scripts`

 **Paso 3:** Verificamos que la base `base_92_20112024.Rds` esté en la carpeta `data`

Todos los materiales los pueden descargar en este link: [Materiales clases](#)

Objetivos de la clase

- Aplicar la prueba **Chi-cuadrado** (χ^2) para evaluar la relación entre dos variables categóricas
- Calcular e interpretar la **V de Cramer** como medida de fuerza de asociación
- Analizar los **residuos tipificados corregidos** para identificar qué celdas contribuyen más a la asociación

¿Qué vimos la última clase?

- ✓ Aplicamos muestreo estratificado con `strata()` y `getdata()`
- ✓ Aplicamos muestreo por conglomerados con `cluster()` en dos etapas

💡 ¡Hoy avanzamos hacia la inferencia sobre variables categóricas!

Actividades prácticas

A lo largo de la clase realizaremos **dos actividades prácticas**, una por bloque temático.

No tienen nota, pero recomiendo resolverlas en un script aparte para que quede como material de estudio.

- Crea un script nuevo e incluye un título, tu nombre, correo y fecha:

```
1 # Actividades Taller 11 Estadística II -----  
2 # M. Constanza Ayala (maria.ayala@uv.cl)  
3 # 09-06-2026
```

¿Cómo analizamos la relación entre dos variables categóricas?

Paso 1 → Existencia de asociación:

- Aplicamos prueba **Chi-cuadrado** (χ^2)
- ¿Existe relación entre las variables?

Paso 2 → Fuerza de la asociación:


- Calculamos **V de Cramer**
- ¿Qué tan fuerte es la relación?

Paso 3 → Contribución de las categorías:

- Analizamos **residuos tipificados corregidos**
- ¿Qué combinaciones de categorías contribuyen más la asociación observada?

Chi-cuadrado (χ^2)

- Permite evaluar la existencia de **asociación** entre dos variables categóricas (nominales u ordinales).
- Trabaja a partir de **frecuencias dentro de tablas de contingencia**: compara lo que se observa en los datos con lo que se esperaría si las variables fueran completamente independientes.
- Nos permite saber si el comportamiento de los atributos de una variable **cambia según los atributos de otra variable**.



Supuestos del Chi-cuadrado

1. **Variables categóricas** — nominales u ordinales. No aplica para variables continuas.
2. **Observaciones independientes** — cada sujeto aparece en una sola celda de la tabla.
3. **Frecuencias esperadas ≥ 5** en al menos el 80% de las celdas de la tabla de contingencia.
4. **Tamaño muestral razonablemente grande** — $n > 30$.

Si alguna celda tiene frecuencia esperada $< 5 \rightarrow$ combinar categorías o usar la prueba exacta de Fisher (solo para tablas 2×2). Verificaremos el supuesto 3 en R al momento de aplicar el test.

Carguemos los paquetes y la base de datos

Base de datos: **Encuesta CEP N° 92**, Agosto–Septiembre 2024. Analizaremos la relación entre actitud frente a la homoparentalidad y sexo.

```
1 options(scipen=999) # Desactivamos notación científica
2 # Paquetes -----
3 library(tidyverse)   # Manipulación de datos y gráficos
4 library(haven)       # Importar bases de datos
5 library(sjPlot)      # Tablas de contingencia
6 library(DescTools)   # V de Cramer
7
8 # Carga y exploración de datos -----
9 data <- readRDS("data/base_92_20112024.Rds")
10 data %>% glimpse()
```

Rows: 1,482

Columns: 157

\$ id_bu	<chr> "1-92", "2-92", "3-92", "4-92", "5-92", "6-92", "7-9...
\$ id_bu_encuesta	<dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 1...
\$ encuesta	<dbl> 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, ...
\$ encuesta_a	<dbl> 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024...
\$ encuesta_m	<dbl> 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8...
\$ pond	<dbl> 0.2096586, 1.2242271, 0.4620447, 1.6158843, 1.249230...
\$ secu	<dbl> 92071, 92173, 92193, 92173, 92071, 92193, 92193, 921...
\$ estrato	<dbl> 8, 20, 20, 20, 8, 20, 20, 20, 20, 20, 20, 12, 20, 10...
\$ region_3	<dbl+lbl> 6, 13, 13, 13, 6, 13, 13, 13, 13, 13, 13, 8, ...
\$ zona_u_r	<dbl+lbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, ...
\$ gse	<dbl+lbl> 4, 3, 3, 3, 4, 3, 3, 2, 3, 3, 2, 4, 3, 3, 3, 3, ...
\$ percepcion_1_a	<dbl+lbl> 3, 3, 14, 1, 1, 5, 9, 14, 1, 1, 1, 1, ...
\$ percepcion_1_b	<dbl+lbl> 7, 9, 10, 10, 3, 10, 14, 9, 9, 3, 5, 3, ...
\$ percepcion_1_c	<dbl+lbl> 10, 26, 4, 2, 9, 13, 2, 26, 17, 6, 13, 13, ...

```

$ percepcion_2      <dbl+lbl> 2, 3, 4, 3, 3, 2, 2, 2, 1, 2, 3, 1, 3, 3, 2, 1, ...
$ percepcion_3      <dbl+lbl> 2, 2, 2, 2, -8, 3, 3, 2, 3, 3, 2, 3, ...
$ bienestar_2       <dbl+lbl> 6, 8, 7, 6, 8, 10, 5, 10, 9, 6, 10, 10, ...
$ bienestar_7_a     <dbl+lbl> 4, 3, 5, 3, 4, 5, 3, 4, 4, 4, 3, 5, 1, 1, 4, 4, ...
$ bienestar_7_d     <dbl+lbl> 5, 5, 5, -7, 5, -7, -7, -7, -7, -7, 5, -7, ...
. . . . .

```

Preparación: recodificar valores perdidos y etiquetar

```
1 # Recodificamos valores no válidos (-8 no sabe, -9 no contesta) como NA
2 data <- data %>%
3   mutate(mtf_45_h = case_when(
4     mtf_45_h %in% c(-8, -9) ~ NA_real_,
5     TRUE ~ mtf_45_h
6   ))
7
8 # Asignamos etiquetas a las categorías
9 data$mtf_45_h <- factor(data$mtf_45_h,
10                        levels = c(1:5),
11                        labels = c("Muy de acuerdo",
12                                   "De acuerdo",
13                                   "Ni de acuerdo ni en desacuerdo",
14                                   "En desacuerdo",
15                                   "Muy en desacuerdo"))
16
17 data$sexo <- factor(data$sexo,
18                   levels = c(1:2),
19                   labels = c("Hombre", "Mujer"))
```

Verificación de NA y reducción de la base

```
1 # Contamos los NA en cada variable
2 sum(is.na(data$mtf_45_h))
```

```
[1] 42
```

```
1 sum(is.na(data$sexo))
```

```
[1] 0
```

```
1 # Eliminamos los NA de la variable mtf_45_h
2 data <- data %>%
3   drop_na(mtf_45_h)
4
5 dim(data) # Verificamos el tamaño resultante
```

```
[1] 1440 157
```

Descriptivos univariados

Antes del análisis bivariado, exploramos la distribución de cada variable por separado:

```
1 # Variable sexo
2 data %>%
3   group_by(Sexo = sexo) %>%
4   summarise(
5     N = n(),
6     Porcentaje = round(100 * n() / nrow(data), 1)
7   )
```

A tibble: 2 × 3

	Sexo	N	Porcentaje
	<fct>	<int>	<dbl>
1	Hombre	564	39.2
2	Mujer	876	60.8

```
1 # Variable homoparentalidad
2 data %>%
3   group_by(Homoparentalidad = mtf_45_h) %>%
4   summarise(
5     N = n(),
6     Porcentaje = round(100 * n() / nrow(data), 1)
7   )
```

A tibble: 5 × 3

	Homoparentalidad	N	Porcentaje
	<fct>	<int>	<dbl>
1	Muy de acuerdo	329	22.8
2	De acuerdo	512	35.6
3	Ni de acuerdo ni en desacuerdo	183	12.7
4	En desacuerdo	279	19.4
5	Muy en desacuerdo	137	9.5

Tabla de contingencia

La tabla de contingencia cruza las dos variables y muestra la distribución conjunta. Con `show.col.prc = TRUE` obtenemos los **porcentajes por columna**, lo que permite comparar las distribuciones entre grupos:

```
1 #Paquete sjPlot
2 sjt.xtab(data$mtf_45_h, data$sexo,
3         show.col.prc = TRUE,      # Porcentajes por columna, para filas ocupar show.row.prc
4         digits       = 2,
5         var.labels   = c("Actitud frente a la homoparentalidad", "Sexo"))
```

Actitud frente a la homoparentalidad	Sexo		Total
	Hombre	Mujer	
Muy de acuerdo	92 16.31 %	237 27.05 %	329 22.85 %
De acuerdo	177 31.38 %	335 38.24 %	512 35.56 %
Ni de acuerdo ni en desacuerdo	79 14.01 %	104 11.87 %	183 12.71 %
En desacuerdo	132 23.4 %	147 16.78 %	279 19.38 %
Muy en desacuerdo	84 14.89 %	53 6.05 %	137 9.51 %

	564	876	1440
<i>Total</i>	100 %	100 %	100 %

$\chi^2=59.073 \cdot df=4 \cdot \text{Cramer's } V=0.203 \cdot p=0.000$

Para interpretar: leemos **dentro de cada columna** (cada grupo de sexo) y comparamos las proporciones. Si los porcentajes difieren entre columnas, hay indicios de asociación.

Chi-cuadrado en R

```
1 # Verificamos el supuesto: frecuencias esperadas >= 5 en al menos el 80% de las celdas
2 chisq.test(data$mtf_45_h, data$sexo)$expected
```

	data\$sexo	
data\$mtf_45_h	Hombre	Mujer
Muy de acuerdo	128.85833	200.14167
De acuerdo	200.53333	311.46667
Ni de acuerdo ni en desacuerdo	71.67500	111.32500
En desacuerdo	109.27500	169.72500
Muy en desacuerdo	53.65833	83.34167

```
1 # Aplicamos el test
2 chisq.test(data$mtf_45_h, data$sexo)
```

Pearson's Chi-squared test

data: data\$mtf_45_h and data\$sexo
X-squared = 59.073, df = 4, p-value = 0.000000000004542

El output entrega tres elementos clave:

- **X-squared:** el estadístico χ^2 calculado
- **df:** grados de libertad = (filas - 1) × (columnas - 1)
- **p-value:** probabilidad de obtener un χ^2 igual o mayor si H_0 fuera verdadera

Si $p < 0.05 \rightarrow$ rechazamos H_0 de independencia $\rightarrow$ existe asociación estadísticamente significativa entre las variables.

Actividad práctica 1 — Chi-cuadrado

Van a trabajar con la variable `religion_14`: *¿Cuál de estas ideas expresa de mejor modo su juicio respecto del aborto?*. En una sección del script llamada `Chi-cuadrado`:

1. Recodifica los valores no válidos de `religion_14` con `case_when()` (valores -8 y -9 como `NA_real_`).
2. Asigna etiquetas con `factor()`: categorías 1 = “Siempre prohibido”, 2 = “Solo en casos especiales”, 3 = “Opción para las mujeres”.
3. Elimina los NA de `religion_14` con `drop_na()` y verifica el tamaño de la base con `dim()`.
4. Calcula los descriptivos univariados de `religion_14` y `sexo` con `group_by()` y `summarise()`.
5. Construye la tabla de contingencia con `sjt.xtab()` y aplica `chisq.test()`. Escribe como comentario (`#`) si se cumplen los supuestos de chi-cuadrado, si existe o no asociación y por qué.

V de Cramer

- La prueba χ^2 indica **si existe** asociación, pero no dice nada sobre su **magnitud**.
- La **V de Cramer** complementa ese resultado: mide la **fuerza de la asociación** entre dos variables categóricas.
- Su rango va de 0 (sin asociación) a 1 (asociación perfecta).

Tamaño del efecto	V de Cramer
Muy débil	< 0.10
Débil a moderada	0.10 – 0.29
Moderada a fuerte	0.30 – 0.49
Fuerte	≥ 0.50

V de Cramer en R

```
1 # Creamos la tabla de contingencia como objeto
2 tabla <- table(data$mtf_45_h, data$sexo)
3
4 # Calculamos V de Cramer con el paquete DescTools
5 CramerV(tabla)
```

```
[1] 0.2025413
```

Para interpretar el resultado, combinamos la significación del χ^2 con el valor de V:

Un valor de $V \approx 0.20$ indica una **asociación débil a moderada**: existe una relación estadísticamente significativa entre actitud frente a la homoparentalidad y sexo, pero las diferencias entre hombres y mujeres no son de gran magnitud.

Residuos tipificados corregidos

El χ^2 y la V de Cramer nos dicen que hay asociación y cuán fuerte es, pero **no señalan dónde está**. Los residuos tipificados corregidos permiten identificar **qué celdas específicas** de la tabla contribuyen más a la asociación observada.

- Un **residuo positivo** indica que esa combinación de categorías ocurre **más de lo que se esperaría** si las variables fueran independientes.
- Un **residuo negativo** indica que ocurre **menos de lo que se esperaría** bajo independencia.
- Valores **$> \pm 1.96$** indican que esa celda contribuye significativamente a la asociación ($\alpha = 0.05$).

Residuos tipificados corregidos en R

```
1 chi <- chisq.test(tabla) # Guardamos el resultado del test
2
3 # Extraemos los residuos tipificados corregidos
4 chi$stdres
```

	Hombre	Mujer
Muy de acuerdo	-4.739503	4.739503
De acuerdo	-2.654157	2.654157
Ni de acuerdo ni en desacuerdo	1.187317	-1.187317
En desacuerdo	3.104115	-3.104115
Muy en desacuerdo	5.582890	-5.582890

Para interpretar: identificamos las celdas con valores fuera del rango ± 1.96 y describimos el patrón.

Ejemplo: un residuo de -4.74 en “Muy de acuerdo / Hombre” indica que **menos hombres de los esperados** están muy de acuerdo con la homoparentalidad. El patrón opuesto en las mujeres (residuo $+4.74$) confirma que **la diferencia entre sexos se concentra en los extremos de la escala de acuerdo**.

Actividad práctica 2 — Análisis completo

Con las mismas variables de la Actividad 1 (`religion_14` × `sexo`):

1. Crea la tabla de contingencia como objeto con `table()`.
2. Calcula la **V de Cramer** con `CramerV()`. Escribe como comentario (`#`) qué tan fuerte es la asociación.
3. Calcula los **residuos tipificados corregidos** con `chisq.test()$stdres`. Escribe como comentario (`#`):
 - ¿Qué celdas tienen valores fuera de ± 1.96 ?
 - ¿En qué categoría y grupo se concentran las diferencias más importantes?
4. Redacta como comentario (`#`) una conclusión integrando los tres resultados: χ^2 , V de Cramer y residuos.

? Preguntas y aclaraciones

 ¿Dudas sobre lo visto hoy?

- Tómense un momento para reflexionar y compartir preguntas sobre el contenido.
- Espacio para responder inquietudes y aclarar conceptos clave.

Resumen clase de hoy

- ✓ Aplicamos la prueba **Chi-cuadrado** (χ^2) para evaluar la existencia de asociación entre dos variables categóricas
- ✓ Calculamos la **V de Cramer** para interpretar la fuerza de la asociación
- ✓ Analizamos los **residuos tipificados corregidos** para identificar qué celdas contribuyen más a la asociación observada



Próxima sesión

- Ejercicio en R recuperativo



Sugerencias lecturas para reforzar R

- Wickham & Grolemund. R for Data Science (acceso en línea biblioteca, en español: <https://es.r4ds.hadley.nz/>)
- [AnalizaR Datos Políticos](#)
- [YaRrr! The Pirate's Guide to R](#)