

Solución Trabajo Final: Estadística II

M. Constanza Ayala

18 de junio, 2026

Objetivo de la entrega

El objetivo de este trabajo es que los y las estudiantes apliquen los contenidos del curso a través del uso de R, con foco en la manipulación de datos, selección muestral, análisis de distribuciones y estimación de intervalos de confianza. El trabajo debe responder una pregunta sociológica con la siguiente base de datos: **Encuesta CEP N°93 (2025)**. Respecto a esta base, se trabajará con las siguientes variables:

- Posición ideológica: `iden_pol_2` (escala 1-10, donde 1 = izquierda y 10 = derecha)
- Grupo socioeconómico: `gse` (ABC1, C2, C3, D, E)

Instrucciones y criterios de evaluación

1. Plantear una pregunta de investigación (0.2 pts)

Formular una pregunta de investigación bivariada y comparativa que involucre las dos variables indicadas. La pregunta debe identificar explícitamente la unidad de análisis y la temporalidad. No se requiere justificación. Realizar en Word.

Por ejemplo: ¿Cómo varía [variable cuantitativa] entre [grupos] en [unidad de análisis] de Chile en [año]?

Respuesta: Por ejemplo, *¿Cómo varía la posición ideológica entre personas de distinto grupo socioeconómico en la población adulta de Chile en 2025?*

- Pregunta bivariada y comparativa bien redactada (**Puntaje: 0,1**).
- Incluye unidad de análisis (personas adultas residentes en Chile) y temporalidad (2025) (**Puntaje: 0,1**).

2. Procesamiento de datos en R (1.0 pts)

- Titular el R Script con los/as integrantes del trabajo. Cada sección del script debe estar identificada con un título como comentario (por ejemplo, **# 1. Preparación de los datos**). Cargar paquetes (solo los que va a ocupar), importar la base y explorar su estructura.
- Recodificar los valores -8 y -9 de `iden_pol_2` a NA mediante `case_when()`.
- Recodificar `gse` en dos grupos: **alto** (ABC1, C2) y **medio-bajo** (C3, D, E).
- Explorar valores perdidos en ambas variables y excluirlos de la base de datos (por ejemplo, con `drop_na`). Solo excluir perdidos de las variables bajo análisis.

Respuesta:

```
#####/  
# Estudiante 1  
# Estudiante 2  
#####/  
  
options(scipen = 999)  
  
# 1. PREPARACIÓN DE LOS DATOS -----  
  
# Paquetes  
library(haven)  
library(sampling)  
library(DescTools)  
library(Rmisc)  
library(kableExtra)  
library(tidyverse)  
  
# Cargar base de datos  
data <- readRDS("data/base_93.Rds")  
  
# Explorar estructura  
#data%>% glimpse()  
  
# Seleccionar variables de interés  
data <- data %>%  
  select(iden_pol_2, gse)  
  
# 2. RECODIFICACIÓN DE VARIABLES -----  
  
# Recodificar -8 y -9 de iden_pol_2 a NA
```

```

data <- data %>%
  mutate(iden_pol_2 = case_when(
    iden_pol_2 %in% c(-8, -9) ~ NA_real_,
    TRUE ~ iden_pol_2
  ))

# Recodificar gse en dos grupos: alto (ABC1, C2) y medio-bajo (C3, D, E)
data <- data %>%
  mutate(gse_2cat = case_when(
    gse %in% c(1, 2) ~ "Alto",
    gse %in% c(3:5) ~ "Medio-bajo",
    TRUE ~ NA_character_
  ))

data <- data %>%
  mutate(gse_2cat = factor(gse_2cat, levels = c("Alto", "Medio-bajo")))

# 3. VALORES PERDIDOS -----

# Exploramos valores perdidos en las variables bajo análisis
data %>%
  summarise(across(c(iden_pol_2, gse_2cat), ~ sum(is.na(.))))

# A tibble: 1 x 2
#   iden_pol_2 gse_2cat
#   <int>      <int>
1       416         0

# gse_2cat no tiene perdidos
# por lo que solo es necesario excluir perdidos de iden_pol_2
data <- data %>%
  drop_na(iden_pol_2)

```

Puntajes:

- Encabezado del script (nombre integrantes, secciones tituladas): 0.1
- Carga de paquetes e importación de base: 0.1
- Exploración de la base de datos: 0.1
- Recodificación de -8 y -9 a NA en iden_pol_2 con case_when(): 0.3
- Recodificación de gse en alto / medio-bajo: 0.3

- Exploración y exclusión de valores perdidos: 0.1

3. Describir el diseño muestral de la encuesta (0.8 pt)

- a. Explicar el diseño muestral del CEP 93. Incluir tipo de muestreo (probabilístico, estratificado, por conglomerados, multietápico, según corresponda), población objetivo, marco muestral y error de muestreo.
- b. Discutir brevemente cómo este diseño puede influir en la representatividad de los resultados y en el análisis estadístico.
- c. Máximo 300 palabras (se corrige hasta la palabra 300). Realizar en Word.

Respuesta:

- La Encuesta CEP N°93 (2025) emplea un diseño probabilístico, estratificado por conglomerados, en tres etapas (manzana/entidad - vivienda - entrevistado/a). La población objetivo corresponde a personas de 18 años y más residentes en todo el país, excluyendo las zonas de difícil acceso (Isla de Pascua, Palena y Antártica Chilena). El marco muestral corresponde a las bases de datos y cartografía asociada del Censo 2017, a partir de las cuales se construyó la estratificación por región y zona urbana/rural. La muestra efectiva fue de 1.493 casos, con una tasa de respuesta de 63,3 % sobre 2.360 personas contactadas. El error muestral fue $\pm 2,8$ %, considerando varianza máxima, un nivel de confianza de 95 % y un efecto de diseño de 1,2. **(Puntaje: 0.4, exige los cuatro elementos: tipo de muestreo, población objetivo, marco muestral y error muestral)**
- Este diseño permite generalizar los resultados a la población adulta del país con un margen de error conocido, pero el efecto de diseño (1,2) indica que la varianza de las estimaciones es mayor que la de un muestreo aleatorio simple equivalente, debido a la estratificación y conglomeración. Esto implica que los errores estándar reales son algo mayores a los que se obtendrían asumiendo independencia entre observaciones si no se incorpora el diseño complejo (variables **estrato**, **secu** y el ponderador **pond**) en el análisis, lo que debe considerarse al interpretar la significancia estadística de los resultados. **(Puntaje: 0.3)**
- Palabras: **(Puntaje: 0.1)**

4. Diseñar una muestra estratificada con R (1.5 pt)

Seleccionar una muestra aleatoria estratificada por `gse` de 300 casos desde la base original, manteniendo las proporciones de cada grupo socioeconómico con `strata` del paquete `sampling`. Llamarla `data_sample`. Asegurar la reproducibilidad mediante `set.seed()`. Realizarlo en R.

Reportar en Word:

- El número total de casos en la base original (incluyendo y excluyendo perdidos).
 - El número de casos en la muestra seleccionada con el muestreo estratificado.
 - Descriptivos básicos de las dos variables en la base original excluyendo perdidos (media y desviación estándar para variable cuantitativa / frecuencia absoluta y relativa para variable categórica).
 - Descriptivos básicos de las dos variables en la muestra seleccionada con el muestreo estratificado (media y desviación estándar para variable cuantitativa / frecuencia absoluta y relativa para variable categórica).
 - Comparar descriptivos de variable `iden_pol_2` de la base original excluyendo perdidos y la muestra seleccionada con el muestreo estratificado, identificando si los descriptivos de ambas bases son similares y qué implicancias tiene esto para la representatividad de la muestra.
 - Explicar cómo el muestreo estratificado preserva la distribución del GSE y cómo se asegura la reproducibilidad del proceso en sus códigos.
- En los siguientes pasos, utilizar la base de datos `data_sample`.

Respuesta:

- N base original (incluyendo y excluyendo perdidos): 1493 y 1077 (**Puntaje: 0.1**)

```
# N total con perdidos
#1493

# N total sin perdidos
nrow(data)
```

```
[1] 1077
```

- Aplicación correcta de muestreo estratificado por `gse` (proporciones preservadas, `set.seed()`) (**Puntaje: 0.5**)
- N muestra seleccionada: 300

```
# 4. MUESTREO ESTRATIFICADO POR GSE -----
```

```
# Revisamos la distribución del estrato  
table(data$gse_2cat)
```

```
Alto Medio-bajo  
314      763
```

```
prop.table(table(data$gse_2cat))
```

```
Alto Medio-bajo  
0.2915506 0.7084494
```

```
# La base debe estar ordenada por la variable de estrato  
data <- data %>% arrange(gse_2cat)
```

```
# Semilla para reproducibilidad  
set.seed(2026)
```

```
# Tamaño proporcional para n = 300 según proporciones de gse_2cat  
estratos <- strata(data,  
  stratanames = "gse_2cat",  
  size = round(prop.table(table(data$gse_2cat)) * 300),  
  method = "srswor")
```

```
# Extraemos la muestra  
data_sample <- getdata(data, estratos)
```

```
# Verificamos distribución resultante  
table(data_sample$gse_2cat)
```

```
Alto Medio-bajo  
87      213
```

```
prop.table(table(data_sample$gse_2cat))
```

Alto	Medio-bajo
0.29	0.71

```
# N muestra
nrow(data_sample)
```

```
[1] 300
```

■ Descriptivos básicos de ambas variables en base original (**Puntaje: 0.2**)

```
# Descriptivos base original (sin perdidos)

# Variable cuantitativa
data %>%
  summarise(
    media = mean(iden_pol_2, na.rm = TRUE),
    de     = sd(iden_pol_2, na.rm = TRUE),
    n      = n()
  )
```

```
# A tibble: 1 x 3
  media    de    n
  <dbl> <dbl> <int>
1  5.42  2.39 1077
```

```
# Variable categórica
data %>%
  count(gse_2cat) %>%
  mutate(prop = round(prop.table(n), 3))
```

```
# A tibble: 2 x 3
  gse_2cat    n prop
  <fct>    <int> <dbl>
1 Alto        314 0.292
2 Medio-bajo  763 0.708
```

■ Descriptivos básicos de ambas variables en muestra seleccionada (**Puntaje: 0.2**)


```
# Descriptivos muestra estratificada

# Variable cuantitativa
data_sample %>%
  summarise(
    media = mean(iden_pol_2, na.rm = TRUE),
    de     = sd(iden_pol_2, na.rm = TRUE),
    n      = n()
  )
```

```
      media      de      n
1  5.44 2.3914 300
```

```
# Variable categórica
data_sample %>%
  count(gse_2cat) %>%
  mutate(prop = round(prop.table(n), 3))
```

```
      gse_2cat      n prop
1         Alto   87 0.29
2 Medio-bajo  213 0.71
```

Comparar descriptivos: La media y desviación estándar de `iden_pol_2` en la muestra estratificada (media = 5,44; DE = 2,39; n = 300) son muy similares a las observadas en la base original excluyendo perdidos (media = 5,42; DE = 2,39; n = 1.077), lo que sugiere que la muestra preserva las características de distribución de la variable. Los resultados muestran que la nueva muestra reducida mantiene la representatividad respecto a la posición ideológica, por lo que las estimaciones obtenidas a partir de `data_sample` pueden considerarse generalizables a la base original. **(Puntaje: 0.2)**

Explicación: El muestreo estratificado preserva la distribución del GSE porque la función `strata()` selecciona casos de forma independiente dentro de cada estrato (Alto / Medio-bajo), respetando las proporciones observadas en la base original (29,2 % Alto, 70,8 % Medio-bajo) mediante el argumento `size`, calculado a partir de `prop.table()`. La reproducibilidad se asegura mediante `set.seed(2026)`, fijado inmediatamente antes de la llamada a `strata()`, por lo que la selección aleatoria es idéntica cada vez que se ejecute el código. **(Puntaje: 0.3)**

5. Explorar la distribución de la variable cuantitativa (0.5 pts)

- Reportar y analizar brevemente las medidas de tendencia central (media y mediana) y dispersión (desviación estándar) de `iden_pol_2`.
- Justificar si la variable sigue una distribución normal. Para ello, graficar un histograma con la curva teórica normal superpuesta con `ggplot` o `hist`.
- Realizar cálculos y gráfico en R, reportar y responder en Word.
- Máximo 200 palabras.

Respuesta:

```
# 5. DISTRIBUCIÓN DE LA VARIABLE CUANTITATIVA -----
tabla_desc <- data_sample %>%
  summarise(
    Media   = round(mean(iden_pol_2, na.rm = TRUE), 2),
    Mediana = round(median(iden_pol_2, na.rm = TRUE), 2),
    DE      = round(sd(iden_pol_2, na.rm = TRUE), 2)
  )
```

```
kable(tabla_desc, booktabs = TRUE, align = "ccc") %>%
  kable_styling(latex_options = c("HOLD_position"))
```

Tabla 1: Medidas de tendencia central y dispersión de identificación política

Media	Mediana	DE
5.44	5	2.39


Interpretación: La variable de identificación política presenta una media de 5,44 y una mediana de 5 en la muestra seleccionada, con una desviación estándar de 2,39. La cercanía entre ambas medidas de tendencia central sugiere una distribución relativamente simétrica en torno al valor central de la escala, es decir, hacia una identificación política situada en el centro. Aunque la desviación estándar relativamente alta indica una dispersión considerable de las respuestas a lo largo de la escala de 1 a 10. **(Puntaje: 0.2)**

```
# Histograma con curva normal teórica superpuesta
ggplot(data_sample, aes(x = iden_pol_2)) +
  geom_histogram(aes(y = after_stat(density)), bins = 10,
    fill = "darkgrey", color = "white") +
  stat_function(fun = dnorm,
    args = list(mean = mean(data_sample$iden_pol_2, na.rm = TRUE),
      sd = sd(data_sample$iden_pol_2, na.rm = TRUE)),
```

```

        color = "red", linewidth = 1) +
labs(title = "Distribución de la posición ideológica (iden_pol_2)",
     x = "Posición ideológica (1 = izquierda, 10 = derecha)",
     y = "Densidad")

```



Interpretación: El histograma muestra que la distribución de la identificación política se concentra fuertemente en torno al valor 5 (centro de la escala), con una caída hacia los valores intermedios y un repunte de frecuencias en los valores extremos. La curva normal superpuesta (en rojo) no logra ajustarse a este patrón, por lo que la variable no sigue una distribución aproximadamente normal. **(Puntaje: 0.2)**

- Palabras: **(Puntaje: 0.1)**

6. Estimar intervalos de confianza (1.5 pt)

Estimar e interpretar el intervalo de confianza de medias para `iden_pol_2` según grupo socioeconómico usando un 95 % de confianza. Reportar gráficamente los IC con `ggplot` y `geom_errorbar`. La interpretación debe mencionar explícitamente el nivel de confianza (95 %) y referirse al parámetro poblacional estimado.

- Realizar estimación y gráfico en R, reportar y responder en Word.
- Máximo 200 palabras.

Respuesta:


```
# 6. INTERVALOS DE CONFIANZA SEGÚN GSE -----
```

```
data_sample %>%
  group_by(gse_2cat) %>%
  summarise(
    n      = n(),
    media  = mean(iden_pol_2, na.rm = TRUE),
    ic_inf = MeanCI(iden_pol_2, conf.level = 0.95, na.rm = TRUE)[2],
    ic_sup = MeanCI(iden_pol_2, conf.level = 0.95, na.rm = TRUE)[3]
  )
```

```
# A tibble: 2 x 5
  gse_2cat      n media ic_inf ic_sup
  <fct>      <int> <dbl> <dbl> <dbl>
1 Alto         87  5.34   4.85   5.84
2 Medio-bajo  213  5.48   5.15   5.81
```

```
# Gráfico de IC con ggplot y geom_errorbar
data_ic <- summarySE(data_sample, measurevar = "iden_pol_2",
                      conf.interval = 0.95,
                      groupvars = "gse_2cat", na.rm = TRUE)

ggplot(data_ic, aes(x = gse_2cat, y = iden_pol_2)) +
  geom_point(color = "grey30", size = 4) +
  geom_errorbar(aes(ymin = iden_pol_2 - ci, ymax = iden_pol_2 + ci),
               width = 0.1, color = "black") +
  labs(title = "Intervalos de confianza (95%) de iden_pol_2 según GSE",
       x = "Grupo socioeconómico",
       y = "Posición ideológica (1 = izquierda, 10 = derecha)")
```



Interpretación: La media de identificación política en la submuestra estratificada fue de 5,34 para el grupo de GSE alto y de 5,48 para el grupo medio-bajo. Con un 95 % de confianza, el intervalo [4,85; 5,84] contiene el verdadero valor poblacional de la posición ideológica promedio para el GSE alto, y el intervalo [5,15; 5,81] contiene el correspondiente al GSE medio-bajo, considerando como población de referencia la base de la Encuesta CEP N°93. Ambos intervalos se traslapan, lo que sugiere que no existe evidencia suficiente para afirmar una diferencia entre la posición ideológica promedio de ambos grupos a nivel poblacional. (Puntaje: 0.4, interpretación correcta con mención de nivel de confianza y parámetro poblacional)

- Estimación correcta de IC en R: (Puntaje: 0.5)
- Gráfico con ggplot y geom_errorbar: (Puntaje: 0.5)
- Palabras: (Puntaje: 0.1)

7. Redactar una conclusión analítica (0.5 pts)

Responder la pregunta de investigación a partir de los intervalos de confianza estimados. Resumir los principales hallazgos y señalar las limitaciones metodológica del análisis para responder la pregunta de investigación. Máximo 300 palabras.

Respuesta: Este trabajo analizó cómo varía la posición ideológica entre personas de distinto grupo socioeconómico en la población adulta de Chile en 2025. A partir de una muestra estratificada de 300 casos basadas en la encuesta CEP 93, se estimaron intervalos de confianza al 95 % para la identificación política según GSE (alto y medio-bajo). Los intervalos obtenidos para ambos grupos se traslapan ampliamente (GSE alto: [4,85; 5,84]; GSE medio-bajo: [5,15; 5,81]), por lo que no se encuentra evidencia de una diferencia en la posición ideológica promedio entre personas de distinto grupo socioeconómico, lo que sugiere que esta variable no constituiría un factor diferenciador relevante de la identificación política en la población de referencia. **(Puntaje: 0.2, responde la pregunta a partir de los IC y resume hallazgos)**

Posibles limitaciones (mencionar al menos una): **(Puntaje: 0.2)**

- Submuestra de la encuesta: los intervalos de confianza se estimaron sobre una submuestra de 300 casos extraída de la base CEP N°93, por lo que la inferencia realizada es válida respecto a esta base como población de referencia, y no necesariamente representa con la misma precisión a la población general de Chile, que es a la que apuntaba originalmente el diseño muestral de la encuesta.
- Pérdida de datos: se excluyeron casos con valores perdidos en `iden_pol_2`, lo que podría afectar la representatividad de la muestra.
- Recodificación en dos categorías: la agrupación de GSE en alto y medio-bajo simplifica la heterogeneidad interna de cada categoría original, pudiendo ocultar diferencias relevantes entre grupos.
- Diseño muestral complejo: el error muestral reportado por la CEP ($\pm 2,8\%$) asume varianza máxima y un efecto de diseño de 1,2, propio de su diseño estratificado y por conglomerados original. Los intervalos de confianza calculados en este trabajo asumen muestreo aleatorio simple y no incorporan dicho efecto de diseño ni los ponderadores muestrales, por lo que podrían subestimar la verdadera variabilidad de las estimaciones.
- Análisis bivariado: solo se consideró la relación entre posición ideológica y GSE, sin controlar por otras variables que pudieran intervenir en esta relación, como edad, sexo o nivel educacional.
- Palabras: **(Puntaje: 0.1)**

Punto base (1.0 pt)

Total: 7.0 pts